

第一章 - 導論

- 1.1 研究背景：線性假設於低頻資料的穩定性
- 動機來源：
- 線性定價的傳統模型：CAPM，Fama-French 等都基於報酬與因變數
- (CAPM 為風險，Fama-French 為因子) 為線性關係。
- An Intertemporal Capital Asset Pricing Model
 - 證明資產定價的線性關係穩定性，基於投資人效用最大化的一階條件
- The Cross-Section of Expected Stock Returns
 - 證實因子與報酬間關係呈現穩定線性關係。

- 1.2 高頻資料下，線性假設隱含的問題
- 金融時序資料在高頻（如日頻）下，線性假設變得脆弱，原因有：
- Empirical Asset Pricing via Machine Learning
 - 高維度特徵相互作用非線性
- Roughing It Up: Including Jump Components in the Measurement, Modeling, and Forecasting of Return Volatility
 - 市場微結構不同於線性結構
- A Test for Independence Based on the Correlation Dimension
 - 金融時序資料在高頻下有違反 iid 和線性假設的跡象

- 1.3 非線性模型之啟發與線性假設的挑戰
- 問題描述：
- 在日頻以及個股單位下，線性假設是否能足夠顯著地描述特徵 - 報酬之間的關係？
 - Asset Pricing with Nonlinear Principal Components
- 加入非線性架構能提升模型表現
- 線性模型可能 misspecified
- Testing Asset Pricing Models under Non-linear Assumptions: Evidence from UK firm level Panel Data
- 或是提出傳統線性架構存在不足，例如低估變異數或誤設條件

- 1.4 研究缺口
- 此論文貢獻：
- 基於日頻與個股為單位的線性與非線性實證論稀缺。多為基於指數和月頻率或以上的實證論文為主。
- 探討日頻相關論文僅為證實日頻之金融時序資料可能違反線性假設，而非實證日頻存在非線性架構。
- 現今財工論文多為探討模型間效能表現，或是模型背後之經濟意涵。
- 尚無結合高頻與線性假設之驗證，並提供相關效能表現的論文。
- 基於排序假設下的實證論文稀缺。

- 1.5 研究主題
- 研究方向：
- 本研究承接線性資產定價之理論基礎，並回應高頻資料下潛在的模型誤設問題，以現代表示學習方法作為檢驗工具，而非預設結論。

第二章 - 相關文獻

- 2.1 線性定價與因子模型
- 過往實證與文獻：
- 傳統資產定價研究以線性因子模型為核心架構，並在月頻資料下成功解釋橫斷面平均報酬
 - **An Intertemporal Capital Asset Pricing Model**
 - 證實線性關係與效用最大化的一階條件之間顯著的高相關性。
 - **The Cross-Section of Expected Stock Returns**
 - 月頻率之橫斷面資料可由線性模型解釋
 - **Common Risk Factors in the Returns on Stocks and Bonds**
 - 多因子的線性模型在低頻具解釋力
 - **Asset Pricing**
 - 提出線性定價是實證分析的標準線

- 2.2 錯誤定義的實證與金融時序數據的非線性證明
- 非線性的理論實證：
- 大量時間序列文獻指出，金融報酬資料普遍違反 iid 與線性假設，顯示線性模型可能存在結構性誤設。
 - A Test for Independence Based on the Correlation Dimension
 - 金融時序資料，尤其在高頻，特別容易出現非線性結構依賴，例如殘差非線性和非 i.i.d
 - Specification, Estimation, and Evaluation of Smooth Transition Autoregressive Models
 - 提出市場具有 regime-dependant dynamics，單一的線性參數模型難以捕捉不同模式下的相關性。
 - regime-dependant dynamics 是指不同模式下，系統的運作規律不同

- 2.3 高頻資料與市場微結構的影響
- 高頻與低頻金融時序資料的報酬運作規律不同：
- 在高頻（如日頻）環境下，市場微結構與短期交易行為使報酬生成機制顯著不同於低頻
 - **Roughing It Up: Including Jump Components in the Measurement, Modeling, and Forecasting of Return Volatility**
 - 波動群聚性，jumps 等存在於高頻資料的特徵非線性
 - **Empirical Market Microstructure**
 - 流動性，訂單數等屬於條件式，非線性

- 2.4 機器學習和表徵學習於資產定價的意義
- 基於機器學習的資產定價之使用原因與優勢：
- 機器學習方法在資產定價中的主要貢獻，在於其捕提高維與非線性交互作用的表示能力
 - Empirical Asset Pricing via Machine Learning
 - 從成效中展現機器學習在捕捉非線性交互作用之重要性
 - Machine Learning in Asset Pricing
 - 將機器學習明確定義為表徵學習，證實其使用 latent features 的正當性

- 2.5 小結
- 研究意義，以及研究方向之統整：
- 現有文獻分別驗證了線性模型在低頻下的有效性、金融資料在高頻下的結構複雜性，以及機器學習方法的表示能力，但尚未有研究直接檢驗線性表示假設在日頻、排序導向設定下是否仍然成立。

第三章 - 數據來源與樣本建構

- 3.1 - 數據來源
- 從 TEJ Pro 蒐集 panel 數據，年份從 2015 至 2025 年，涵蓋以下：
- TEJ 股價資料庫
 - 未調整股價 (日) - 股價
 - 股價報酬 (日) - Beta
 - 未調整股價 (日) - 報酬率
- 2. TEJ 籌碼資料庫
 - 籌碼分布
 - 籌碼動向 & 報酬

- 3.2 - 特徵分類
- 使用數據的分配：
 - 價量與財報類指標：
 - 未調整股價 (日) - 股價
 - 股價報酬 (日) - **Beta**
 - 未調整股價 (日) - 報酬率
 - 交易類指標
 - 籌碼分布
 - 籌碼動向 & 報酬

- 3.4 - 樣本分割與擴張視窗方式
- 對於樣本如何分割，以及訓練，驗證，測試三階段的時期分配與原因如下：
- 數據分割
 - 2015-2022 年為訓練和驗證 (驗證指的是超參數調整)，使用擴張窗口方式：
- 第一輪從 2015-2019 年，2020 年用於驗證。
- 第二輪從 2016-2020 年，2021 年用於驗證。
- 第三輪從 2017-2021 年，2022 年用於驗證。
- 2023 年至 2025 年用於測試樣本外表現。
- 採用此方法有兩個好處：
 - 能夠抗衡市場結構變化，訓練順序和年份新舊時序相關，有隱含舊年份的權重較輕的意味。
 - 此方法假設市場結構會變化，所以最舊年份在新一輪訓練將被丟棄，符合現實情況。
 - 共同特徵工程中的聚類與 PCA 為無監督學習，不會產生 look-ahead bias，所以將全體數據一次進行完成。

- 3.5 - 數據範圍與法律聲明
- 關於此論文的研究範圍和法律聲明：
- 本研究聚焦於台灣股票市場之個股日頻資料，研究結論應理解為在此資料頻率與樣本市場環境下之實證結果，而非對所有市場或頻率的普遍性推論
- 本研究為學術性實證，並非市場獲利導向報告，若任何人以此報告進行交易或策略參考導致財產虧損，本論文作者與指導教授以及學校單位皆不負任何責任。

第四章 - 方法論

- 4.1 - 研究假設和數值架構

- 根據第一章的研究假設延伸：
- 若股票報酬與特徵之關係可由線性表示充分描述，則基於線性特徵工程與非線性表示學習所構建的模型，在排序與投資績效上不應呈現系統性差異；反之，若存在顯著非線性結構，則非線性表示應帶來可檢測的改善。

- 4.2 - 線性假設下之特徵工程
 - 4.2.1 - 線性假設和特徵空間
 - 透過檢定，再進行特徵工程前都作相關檢定，確保步驟嚴謹性：
 - 將空白值補齊，根據特徵不同使用不同方式
 - 金融數據多較為完整，若有需求，再根據不同特徵查詢論文進行
 - 將離散型（單位為整數的特徵，如外資買賣超）特徵使用 Gumbel 函數連續化

- 4.2 - 線性假設下之特徵工程
- 4.2.2 - 主成分分析以及階層群聚作為線性降維處理
 - 假定特徵是線性關係之下，透過檢定確保聚類和降維的合理性：
 - **Bartlett's Test of Sphericity** 檢定變數是否為隨機架構，若
 - 為隨機架構，直接送入模型和神經網路。若具有足夠相關性，
 - 意即具有共通架構，往下做以下檢定。
 - **Kaiser-Meyer-Olkin** 檢定變數線性關係強度，意即是否適合進行 **PCA**，若檢定值過低，表示共通變異過低，不適合 **PCA**。
 - **Hopkins Statistic** 檢定數據是否比隨機均勻分布更具有架構，若檢定值高於 **0.7**，通常是為具有顯著群聚，可做分群分析。反之則不必進行。
 - 使用 **PCA** 進行降維，抓取最大特徵值方向來過濾各分群噪音
 - **The Elements of Statistical Learning**
 - **PCA** 假定線性關係
 - **Statistical Arbitrage in the US Equities Market**
 - **PCA** 用於金融數據的實際論文案例

- 4.3 - 非線性假設下之特徵工程處理

- 4.3.1 - 非線性之表徵學習的動機

- 為何進行非線性假設下的特徵工程處理：

- 若非線性存在於特徵和時間的二維動態關係中，則僅靠靜態線性轉換可能不足，而序列式表示學習能提供更具有表達力的特徵空間。

- 4.3.2 - 基於長短期記憶網路的潛在變數建構

- 為何使用 **LSTM** 作用挖掘非線性的潛在變數的工具，以及此步驟的合理性。本論文不將 **LSTM** 視為最終預測模型，而是作為一種非線性映射工具，將原始特徵序列轉換為低維表徵：

- **Forecasting Volatility with LSTM Networks**

- 使用 **LSTM** 進行金融時序數據的表徵學習工具

- **Deep Learning for Asset Pricing**

- **LSTM** 用於資產定價和報酬預測的實際論文案例

- 4.4 - 預測模型與評分函數
- 4.4.1 - 線性預測模型
- 線性模型作為基準：
- 回歸類
 - 一般複回歸
 - 將共同特徵工程處理過的聚類特徵進行
 - 共線性
 - 誤差項獨立
 - 誤差項同質
 - 三項檢定，若不通過則調整聚類特徵確保高斯 - 馬可夫定理成立。調整方式可能為：
 - Box-Cox
 - 指數轉換
 - 將聚類後特徵改用 PCA 外方式降維
 - Ridge和Lasso回歸
 - 標準化 (Z-score)
 - 同複回歸，將會有兩種損失函數等出的結果，所以此部分會有 4 組結果

- 4.4.2 - 樹狀非線性預測模型
- 作為非線性模型的代表：
- 機器學習模型
 - Random Forest
 - 標準化 (Z-score)
 - XGBoost
 - 標準化 (Z-score)
 - Empirical Asset Pricing via Machine Learning
 - 實際使用上述兩個演算法的實證論文

第五章 - 性能評估

- 5.1 - 評估原則
- 如何看待評估指標，以及評估的方向：
- 本論文的績效評估重點不在於追求單一策略的最優報酬，而在於比較不同特徵表示方法在相同投資框架下是否產生顯著不同的排序與投資結果。
 - 例如：同樣使用 **XGBoost** 的情況下，基於線性假設的特徵工程與非線性假設的特徵工程下輸出的特徵對於 **XGBoost** 在夏普值或是累積報酬等評估指標是否有顯著不同。
 - 此評估方向並非著重於誰的累積報酬，夏普值更好，而是基於相同模型下，輸入兩種特徵工程的特徵是否對於相同指標有顯著變化。
- 顯著與否取決於統計檢定結果

- 5.2 - 個股評分與排名機制
- 如何進行個股評分與評分機制如何設計與運作：
 - 各模型基於特徵輸出預期報酬，並以此進行高低排名
 - 每日依照排名調整做多做空之標的物
 - 排序本身是研究對象，而非點預測

- 5.3 - 投資組合建構方式
- 如何建構組合：
- 依照預期報酬形成排名，等權重地做多前 10% 以及做空後 10% 排名之個股
 - 10 % 之相關論文依據：
 - Empirical Asset Pricing via Machine Learning
 - 使用前後 10 % 進行長短期策略
 - Profitable predictability in the cross section of stock returns
 - 對於個股排序後，發現前後 10 % 做長短期策略的表現顯著優於其他組合。

- 5.4 - 成效矩陣
- 將指標置於列，各種演算法和兩種假設下之特徵工程的組合置於欄：
- 指標種類：
 - 排序與預測相關，衡量排序品質：
 - Rank IC : Spearson's R，median，IQR
 - 投資績效相關，衡量排序是否改善經濟意涵：
 - 測試期內累積報酬
 - 夏普值
 - 最大回撤
- 演算法種類：
 - 迴歸類
 - 複迴歸
 - 脊迴歸
 - Lasso 迴歸
 - 樹模型
 - XGBoost
 - Random Forest
- 特徵工程種類：
 - 線性假設
 - 含 PCA 和聚類，但可能依照檢定結果僅有其中一種或都不做
 - 非線性假設
 - LSTM 產生的 latent features

- 成效矩陣範本：

- 排序與預測相關：(每種演算法各占一格)

指標 / 演算法 + 特徵工程	回歸+線性	回歸 + 非線 性	樹模型 + 線 性	樹模型 + 非 線性
Spearson's r				
中位數				
四分位數				

- 投資績效相關：(每種演算法各占一格)

指標 / 演算法 + 特徵工程	回歸+線性	回歸 + 非線 性	樹模型 + 線 性	樹模型 + 非 線性
測試期累積 報酬				
夏普值				
最大回撤				

- 5.5 - 統計顯著性檢定
- 5.5.1 - 成對比較的架構
- 比較的樣本形式：
- 在測試期內：
 - 同一日
 - 同一個股集群
 - 不同表示方式 / 模型
 - 例如：比較迴歸類分別輸入線性和非線性假設的特徵
- ， 在同一日 ， 同一個股的預測報酬為一對

- 5.5.2 - wilcoxon rank-sum test
- 為何使用該檢定：
 - Nonparametric Statistical Methods
 - 同 1.2 節，金融時序數據常不符合 i.i.d 且有厚尾特性，所以不適合以 CLT 假設常態分布。故以不須常態假設的該檢定較為合適。該檢定適合處理排序差異的中位數是否為 0，來判定是否有顯著差異
- 5.5.3 - 檢定結果解釋
- 將以 p-value 做為檢定結果，並解釋涵義：
- 不論顯著與否，均強調此重點：
 - 統計顯著性表示不同特徵表示方法在相同模型與投資規則下產生系統性差異，而非保證其在所有市場環境中均能帶來超額報酬。

- 5.6 - 小結
- 根據結果，表示各演算法與特徵工程組合下的成效，並強調以下：
 - 本章建立一套以排序為核心、結合經濟績效與統計檢定的評估框架，為後續分析線性與非線性表示所導致的差異提供一致且可比較的基準。模型間的比較用於分辨差異出在特徵還是模型上

第六章 - 線性與非線性之判定

- 6.1 - 結構診斷之動機
- 為何已經有績效和指標，還需要進一步的統計判定：
 - 即使非線性表示在排序或投資績效上表現較佳，該結果仍可能源於樣本特性或偶發性市場狀態。因此，有必要進一步檢驗模型殘差是否仍存在未被線性結構捕捉的依賴關係，以確認績效差異是否反映真實的結構性非線性。

- 6.2 - 排序結構下的殘差結構

- 殘差如何產生，是怎麼樣的資料：
- 模型輸出預期報酬，扣除掉測試期對應個股與日期的實際報酬，產生的差值
- 殘差保留時間特徵的同時，也持有減去模型所隱含的線性或非線性解釋部分，剩餘的資訊量

- 6.3 - Brock-Dechert-Scheinkman test

- 為何使用該檢定 (簡稱 BDS test) :
- A Test for Independence Based on the Correlation Dimension
 - BDS test 用於檢驗時間序列是否違反 i.i.d 假設，若拒絕虛無假設，表示序列中存在某種形式的結構性依賴。
 - 僅對迴歸類進行，因樹模型類已經解釋非線性部分。

- 6.4 - 過濾線性結構

- 在執行 **BDS test** 之前，先過濾殘差中的線性部分，避免檢定誤判：
- 對殘差執行 **ADF** 檢定，確保時序弱平穩性
- 套用 **ARIMA** 模型，過濾殘差中線性結構
- 對輸入殘差的 **ARIMA** 的殘差執行 **BDS** 檢定
- 拒絕 **H0**：
 - 表示模型中殘留線性模型無法捕捉之某種結構性依賴，意即存在非線性結構

- 6.5 - 檢定與成效之共同分析
- 將成效矩陣的檢定和殘差檢定結合起來，進行數據的質性分析與結論探討：
- 可能結果 (最小且完備的所有可能)：
- 第一種：
 - 非線性表徵 (latent features) 較好 + BDS test 拒絕 H_0
- 非線性結構存在，且非線性表示能有效利用該結構
 - 第二種：
 - 非線性表徵 (latent features) 較好 + BDS test 不拒絕 H_0
- 非線性表示在績效上較佳，但檢定未顯示可檢測的非線性結構
 - 第三種：
 - 線性表徵較好 + BDS test 拒絕 H_0
- 存在非線性結構，但該結構在經濟上不可利用。
 - 第四種：
 - 線性表徵較好 + BDS test 不拒絕 H_0
- 線性假設在該市場與頻率下具備實證適用性。
 - 第五種：
 - 績效無顯著差異 + BDS test 拒絕 H_0
- 線性表示不僅結構上足夠，在經濟績效上也顯著優於非線性表示
 - 第六種：
 - 績效無顯著差異 + BDS test 不拒絕 H_0
- 雖存在非線性結構，但非線性表示反而表現較差。

第七章 - 結論

- 7.1 - 主要發現與涵義
- 將根據回測結果撰寫但重點將如下範例：
 - 本論文檢驗日頻股票資料下線性表示的適用性，並透過非線性表示作為比較基準。實證結果顯示，非線性表示在部分情境下能帶來顯著的績效改善，且該改善在結構診斷上與超出線性時間動態的依賴相一致。然而，亦存在線性表示已能充分描述資料結構，或非線性結構未能轉化為穩定績效之情境，顯示線性假設在日頻環境下具備條件式適用性

- 7.2 - 方法論與實踐上的啟發
- 將配合回測結果做修改，但重點將如下：
- 績效差異需搭配結構檢定：
 - 單純的模型績效比較不足以支持對資料生成機制的推論
- 非線性方法並非普遍優越：
 - 非線性表示的效果取決於資料是否包含可被利用的結構
- 表示學習可作為檢驗工具：
 - 非線性表示有助於檢驗線性假設，而非僅作為預測器

- 7.3 - 未來方向與限制
- 告知讀者此論文的研究界線與未來可能持續推演的方向：
 - 本論文僅聚焦於單一市場之日頻資料，相關結論應理解為在該資料頻率與市場環境下之實證結果。此外，結構診斷方法僅提供非線性依賴的檢測，而非形式識別。未來研究可進一步探討不同市場、資料頻率，或結合經濟理論導向的非線性表示方法

- 7.4 - 結語
- 整篇論文的結論，以及作者的觀點並非在工程與績效問題，而是解決與貢獻一項疑問：
 - 整體而言，本論文顯示關鍵問題不在於線性或非線性方法何者優越，而在於線性表示於何種條件下仍然適用。透過結合績效比較與結構診斷，本論文提供一個更細緻的視角，理解高頻環境下線性假設的實證角色。

實際數據結果

結論相關

演算法	配對樣本數	PCA誤差中位數	LSTM誤差中位數	誤差差異顯著性(P-val)	較優特徵	BDS檢定(P-val)	存在非線性結構	最終實證結論					
OLS	119098	1.375279347	1.376021124	8.5871E-28	PCA	5.85159E-21	Yes	第三種：存在非線性結構，但該結構在經濟上不可利用。					
Ridge	119098	1.26096035	1.262639057	0	PCA	1.24359E-06	Yes	第三種：存在非線性結構，但該結構在經濟上不可利用。					
Lasso	119098	1.349791936	1.347851999	9.77568E-05	LSTM	7.90904E-07	Yes	第一種：非線性結構存在，且非線性表示能有效利用該結構。					
XGBoost	119098	1.370751342	1.379787679	9.75438E-20	PCA	5.73313E-21	Yes	第三種：存在非線性結構，但該結構在經濟上不可利用。					
RandomForest	119098	1.371109615	1.379051046	1.17484E-27	PCA	5.93328E-21	Yes	第三種：存在非線性結構，但該結構在經濟上不可利用。					